

논문 분석 결과

1. 서론

Description 논문에서는 유니버설 로봇(Universal Robots)사의 UR3 협동로봇 운영 데이터셋인 UR3 CobotOps를 활용하여, 기존 모델의 불투명성을 극복하고 설명 가능한 고장 진단(Interpretable Fault Diagnosis)을 달성하고자 했다.

이를 위해 데이터 간의 수학적 인과 구조를 엄밀히 규명하는 량-클리만 정보

흐름(Liang-Kleeman Information Flow) 이론을 퍼지 인지 지도(Fuzzy Cognitive Map, FCM) 모델과 결합한 IF-FCM 방법론을 제안했다.

논문은 UR3 로봇의 핵심 고장 유형인 보호 정지(Protective Stop)와 그립 유실(Grip Lost)의 실제 물리적·인과적 원인을 규명하고, 제안한 모델이 기존의 전통적 기법에 비해 우수한 예측 성능과 신뢰할 수 있는 인과적 설명력을 가짐을 통계적 분석(ANOVA)을 통해 검증하고자 하였었다.

2. 데이터셋 및 분석 환경 (Dataset & Experimental Setup)

2.1. UR3 CobotOps 데이터셋의 수집 구조 및 변수(Feature) 정의

데이터셋은 총 7,409개의 행(Row)과 24개의 열(Column)로 구성되어 있으며, 중복된 레코드는 존재하지 않다.

변수의 구성을 물리적·기능적 특성에 따라 분류하면 다음과 같다.

1. 시간 및 주기 정보: **Timestamp**, 운전 주기를 나타내는 **cycle**. 이 변수들은 로봇의 연속적인 거동 흐름을 추적할 수 있게 한다.
2. 관절별 물리량 센서 데이터: 로봇을 구성하는 6개의 관절(J0부터 J5까지) 각각에서 수집된 전류(Current J0~5), 온도(Temperature J0~5), 회전 속도(Speed J0~5)가 포함된다. 이는 로봇의 역학적 상태를 반영하는 핵심 연속형 변수들이다.
3. 말단 툴(Tool) 상태: 그리퍼나 흡착 패드가 소모하는 전류량인 **Tool_current** 변수가 포함되어 있다.
4. 상태 및 타겟 변수: 로봇의 안전 메커니즘 작동 여부를 나타내는 **Robot_ProtectiveStop**과 말단 그리퍼가 물건을 놓쳤는지를 기록한 **grip_lost**가 이진(Binary) 형태의 범주형 변수로 제공된다.

2.2. 탐색적 데이터 분석(EDA)을 통한 데이터 특징 파악

2.2.1. 센서 데이터의 동시성 결측치(Missing Value) 발생 패턴 분석

Num, **Timestamp**, **cycle**, **grip lost** 등의 변수를 제외한 대부분의 센서 데이터 열(전류, 속도, 온도 및 보호 정지 라벨 등)에서 공통적으로 54개(일부 열은 46개)의 결측치가 동시에 발생했다.

이러한 동시성 결측치는 임의의 확률로 데이터가 누락되는 일반적인 노이즈(MCAR)와 다르다. 논문에서 설명한 실험 환경을 고려할 때, 로봇이 물리적 충격을 받거나 제어 한계를 벗어나 보호 정지(Protective Stop) 상태에 진입하는 순간, 시스템 내부의 제어기(Controller)와 데이터 로깅 컴퓨터 간의 통신 패킷 드롭(Packet Drop)이나 일시적인 센서 통신 마비가 발생했음을 시사한다. 따라서 이 결측치들은 단순한 에러로 치부하기보다 고장 징후와 밀접한 연관이 있는 시스템 작동 중단 순간의 공백으로 해석하는 것이 타당하다.

2.3. 학습을 위한 데이터 정제 및 스케일링(Scaling) 프로세스

세세한 인과 관계 규명과 머신러닝 모델의 안정적인 학습을 위해 다음과 같은 전처리 프로세스를 수행한다.

1. 결측치 처리: 통신 누락으로 인해 주요 센서 데이터 전체가 비어 있는 54개의 행은 대체(Imputation)할 경우 오히려 모델에 왜곡된 인과 관계를 주입할 수 있으므로, 데이터의 순수성을 유지하기 위해 제거(Drop) 방식을 택한다. 결측치를 정제한 후 최종 학습에 사용되는 데이터는 총 7,355행이다.
2. 이상치(Outlier)에 대한 물리적 해석: 일반적인 데이터 분석에서는 정규분포를 벗어나는 극단값을 이상치로 보고 제거하지만, 본 로봇 데이터셋에서는 전류가 급격히 치솟거나 속도가 급 변하는 이상치(Outlier) 자체가 부하(Workload)의 증거나 '고장 조짐을 나타내는 핵심 신호이다. 따라서 인위적인 이상치 제거는 수행하지 않는다.
3. 데이터 스케일링(Scaling): 관절 변수 중 전류(A 단위, 수십~수백 단위 변화)와 온도(°C 단위, 상대적으로 완만한 변화)는 서로 값의 범위(Scale)가 크게 다르다. 4장에서 다룰 K-최근접 이웃(KNN)이나 5장의 K-평균(K-Means) 군집화와 같이 거리 기반 알고리즘을 사용할 때 특정 변수의 단위가 크다는 이유만으로 모델이 그 변수를 과도하게 반영하는 것을 막기 위해, 모든 연속형 센서 변수에 대해 평균을 0, 표준편차를 1로 맞추는 표준화(Standardization, StandardScaler)를 적용하여 데이터의 스케일을 통일한다.

3. 이론적 배경 (Theoretical Background)

본 논문에서는 단순히 높은 예측 성능만을 추구하는 블랙박스형 머신러닝 대신, 변수 간의 투명한 인과관계를 설명할 수 있는 IF-FCM(Information Flow-Based Fuzzy Cognitive Map) 방법론을 제시한다. 이를 구성하는 두 가지 핵심 축인 퍼지 인지 지도와 정보 흐름 이론의 개념은 다음과 같다.

3.1. 퍼지 인지 지도 (Fuzzy Cognitive Maps, FCM)

퍼지 인지 지도(FCM)는 인공지능망의 연산 능력과 퍼지 논리의 시스템 모델링 능력을 결합한 소프트 컴퓨팅 방법론으로, 시스템의 복잡한 동적 메커니즘을 시각적이고

직관적으로 표현하는 도구이다. 최종 수렴된 각 노드의 활성화 값 크기를 통해 특정 예측 시점에 어떤 입력 변수(노드)가 결정에 가장 큰 영향을 미쳤는지 직관적으로 파악할 수 있어 우수한 로컬(Local) 설명력을 제공한다.

3.2. 량-클리만 정보 흐름 (Liang-Kleeman Information Flow, L-K IF)

일반적인 머신러닝 모델들은 데이터 내의 상관관계(Correlation)를 기반으로 학습한다.

하지만 상관관계는 실제 물리적 원인과 결과를 반영하지 못하며, 우연히 같이 변하는 변수들을 인과관계로 오인하는 가짜 상관관계(Spurious Correlation) 문제를 유발하기 쉽다.

이를 극복하기 위해 본 논문이 도입한 수학적 장치가 량-클리만 정보 흐름(L-K IF) 분석이다. (데이터 간의 관계를 컴퓨터가 알아서 학습하되, 헛소리(노이즈)를 하지 못하도록 인간이 길을 먼저 닦아놓고(1단계) 그 안에서 정밀하게 튜닝(2단계)하겠다)

3.3.3. 사회적 학습 입자 군집 최적화 (Social Learning PSO, SL-PSO)

일반적인 경사하강법(Gradient Descent)은 FCM과 같은 순환형 구조에서 로컬 미니마(Local Minima)에 빠질 위험이 크다. IF-FCM은 이를 해결하기 위해 SL-PSO를 도입한다. 기존 PSO와 달리 최상위 성능을 보이는 다수의 피어(Peers)인


'데몬스트레이터(Demonstrators)'들로부터 동시에 사회적 학습을 수행하여 지역 해를 탈출하는 능력이 뛰어난 전역 최적화 알고리즘이다. 고차원의 복잡한 가중치 탐색 공간에서 최적의 해를 빠르고 안정적으로 찾아내는 이점이 있다.

4. 모델 학습 환경 및 검증 기법 (Experimental Validation)

본 장에서는 논문에서 고장 진단 예측력을 객관적으로 신뢰하고 오버핏(Overfitting)을 방지하기 위해 채택한 통계적 검증 도구와 불균형 데이터 처리 기법을 검토한다.

4.1. 클래스 불균형 해결을 위한 SMOTE-ENN 기법

산업 현장에서 수집되는 고장 진단 데이터셋의 대표적인 한계는 정상 작동 데이터에 비해 고장(Anomaly) 데이터의 비중이 극도로 적은 클래스 불균형(Class Imbalance) 문제이다.



SMOTE (Synthetic Minority Over-sampling Technique): 단순히 소수 클래스를 복제하는 대신, **KNN** 알고리즘을 활용해 이웃한 소수 샘플 간의 선분 상에 가상의 새로운 고장 데이터를 생성하여 데이터 다양성을 높인다.

ENN (Edited Nearest Neighbors): 오버샘플링 결과물 중 클래스 간 경계선에 위치한 노이즈나 잘못 매칭된 샘플들을 주변 이웃(**KNN**)의 다수결 원칙에 근거해 지워나간다.

평가 및 시사점: **SMOTE**와 **ENN**을 결합함으로써 분류 경계면이 깨끗하게 정돈되어, 머신러닝 모델이 정상 상태를 고장으로 오진하는 **false alarm**을 줄이고 실질적인 분류 마진을 극대화한다. 시계열 순서가 일부 깨질 우려가 있으나, 본 연구가 시간 흐름 자체보다 센서의 순간적 패턴을 감지하는 것에 중점을 주었으므로 타당한 전처리 접근법이다.

4.2. 계층적 10-폴드 교차 검증 (Stratified 10-Fold Cross-Validation)

모델의 일반화 성능을 정밀하게 측정하고 특정 학습 데이터에만 과적합되는 현상을 검증하기 위해 **Stratified 10-Fold Cross-Validation**을 활용한다.

전체 데이터셋을 동일한 크기의 **10개 그룹(Fold)**으로 분할한 후, **9개 그룹**으로 학습시키고 나머지 **1개 그룹**으로 검증을 수행하는 과정을 **10회 반복**한다. 계층적(**Stratified**) 분할로 일반적인 **K-Fold**와 달리 각 폴드가 전체 데이터셋의 정상 상태 대비 고장 상태의 비율을 정확하게 보존하도록 나눈다. 이를 통해 특정 폴드에 고장 데이터가 쏠리거나 누락되어 검증 결과가 편향되는 오류를 차단하고 평가 결과의 공신력을 보장한다.

4.3. 변수 유의성 규명을 위한 분산 분석 (ANOVA)

ANOVA(Analysis of Variance, 분산 분석)는 서로 다른 집단 간의 평균값 차이가 우연에 의한 것인지 통계적으로 의미가 있는 수준인지를 검증하는 가설 검정 방법이다.

본 논문에서는 제안된 **IF-FCM** 모델이 가중치 학습을 통해 도출한 주요 인자들의 순위가 실제 물리계의 인과성과 부합하는지 교차 검증하는 독립적인 기준점(**Ground Truth**)의 역할을 수행한다. 보호 정지(**Protective Stop**) 원인으로 **ANOVA** 분석 결과 변수들 중 로봇의 작업 부하(**workload**)가 가장 유의미한 영향(**F -value = 7.78 F-value=7.78 , p -value = 0.0032 p-value=0.0032**)을 미치는 인자임이 검증되었다.

그립 유실(**Grip Lost**) 원인으로 **ANOVA** 분석 결과 그리퍼의 그리핑 힘(**gripping force**)이 지대한 영향(**F -value = 5.38 F-value=5.38 , p -value = 0.0135 p-value=0.0135**)을 주는 핵심 인자임이 통계적으로 입증되었다.

데이터셋을 정상 조건과 특정 고장 조건 세부 집합으로 나눈 뒤 **ANOVA**를 적용하여 개별 센서 변수들의 평균 차이를 통계적으로 분석하였으며, 이는 **IF-FCM** 모델이 산출한 설명 가이드라인(변수 중요도 순위)의 우수성을 정량적으로 지지하는 척도로 사용된다.

6. 결론 및 학술적 시사점 (Conclusion)

6.1. 논문의 핵심 공헌점 요약

본 논문은 산업용 로봇 고장 진단에서 발생하는 AI의 블랙박스(속을 알 수 없는) 문제를 해결하기 위해, 퍼지 인지 지도(FCM)와 정보 흐름(L-K IF) 이론을 결합한 IF-FCM 모델을 제시하였다.

성과와 설명력의 두 토끼 확보로 가짜 상관관계(예: 단순히 작동 시간이 길어져 온도가 올라간 것)를 수학적으로 걸러내어, 고장 진단율을 높임과 동시에 통계적 정답지(ANOVA)에 부합하는 진짜 고장 원인을 정확히 찾아냈다.

가상 데이터가 아닌 실제 산업용 협동 로봇(UR3)의 작동 데이터를 바탕으로 검증하여 실무적 유용성을 입증하였다.

6.2. 기초 머신러닝 프로젝트 적용을 위한 데이터적 시사점

본 논문과 'UR3 CobotOps' 데이터셋 분석을 통해 얻은 교훈은 향후 우리가 수행할 회귀, 분류, 군집화 프로젝트에 매우 중요한 나침반 역할을 한다.

① 회귀(Regression) Task 수행 시 주의할 점 "상관관계는 인과관계가 아니다"를 명심할 것: 로봇 관절의 온도를 예측하는 회귀 모델을 만들 때, 작동 주기(cycle)나 시간(Timestamp)처럼 단순히 비례해서 증가하는 변수를 무작정 모델에 넣으면 성능은 높게 나올지언정 물리적으로 왜곡된 모델이 될 수 있다. 실제 물리적 연관성(전류량, 속도 등)이 있는 변수를 신중히 선택해야 한다.

② 분류(Classification) Task 수행 시 주의할 점 데이터 스케일링의 필수성: 관절 전류(A 단위)와 온도(°C 단위)는 값의 범위가 완전히 다르다. 우리가 배운 KNN이나 의사결정나무 같은 분류 모델을 적용하기 전에, 반드시 평균을 0, 표준편차를 1로 맞추는 표준화(StandardScaler) 전처리를 거쳐야 특정 변수가 모델을 지배하는 오류를 막을 수 있다.

클래스 불균형 고려: 고장 데이터는 정상 데이터에 비해 훨씬 적다. 단순 학습을 시키면 모델이 무조건 '정상'으로만 예측할 확률이 높으므로, 샘플링 기법(SMOTE 등)을 고려하여 비율을 맞춰주어야 정확한 고장 분류기를 만들 수 있다.

③ 군집화(Clustering) Task 수행 시 주의할 점 이상치(Outlier)를 함부로 지우지 말 것: 일반적인 K-Means 군집화에서는 정규분포를 벗어나는 튀는 값을 노이즈로 보고 삭제한다. 하지만 로봇 데이터셋에서 갑자기 치솟는 전류값이나 급변하는 속도는 '무거운 부하를 견디는 중'이거나 '고장 직전의 위험 상태'를 나타내는 핵심 신호이다. 따라서 이상치를 보존한 상태에서 군집화를 진행해야 정상 상태와 고장 전조 상태를 올바르게 그룹화할 수 있다.

6.3. 통계 및 인과 분석으로 규명한 진짜 고장 원인 (Physical Causality) 논문의 핵심
알고리즘(IF-FCM)과 통계 분석(ANOVA)을 통해 규명한 두 가지 고장 유형의 진짜 기계적 원인은 다음과 같습니다.

[고장 유형 A] 보호 정지 (Protective Stop) 진짜 원인: 로봇이 견딜 수 있는 무게보다 과도한 부하(Workload)가 실렸을 때 발생.

데이터상의 징후: 무거운 부하를 버티기 위해 지탱 관절인 2번 관절 전류(Current J2)와 1번 관절 전류(Current J1)가 급격하게 치솟음. 이 신호를 감지하여 모터 타격을 막기 위해 로봇이 스스로 전원을 차단하고 멈춤.

[고장 유형 B] 그립 유실 (Grip Lost) 진짜 원인: 부족한 움켜쥐는 힘(Gripping Force)

상태에서, 원심력 및 무게중심의 변화로 물건이 튕겨 나감.

데이터상의 징후: 무거운 물건을 천 채로 로봇 손목에 해당하는 5번 관절 속도(Speed J5)와 4번 관절 속도(Speed J4)가 급격히 회전할 때, 무게 중심이 흐트러지며 물건을 놓치게 됨. 이때 관절 전류(Current J2) 역시 요동침.

[부록] 핵심 개념 및 기법 상세 설명

1. 퍼지 인지 지도 (FCM, Fuzzy Cognitive Map) : FCM은 쉽게 말해 스스로 계산하고 추론할 수 있는 스마트한 마인드맵입니다. 우리가 복잡한 생각을 정리할 때 동그라미(개념)를 그리고 화살표로 연결하듯이, 시스템의 변수들을 노드로 만들고 이들의 관계를 플러스(+)와 마이너스(-) 화살표로 연결한 지도입니다. 퍼지(Fuzzy)라는 이름이 붙은 이유는 "원인이 결과를 100% 변화시킨다"가 아니라, "어느 정도(예: 매우 강하게, 약간 약하게) 영향을 준다"처럼 인간의 애매모호한 언어적 표현을 컴퓨터가 계산할 수 있는 $[-1, 1]$ 사이의 숫자로 바꾸어 연산하기 때문입니다.

속을 보여주는 투명한 AI를 만들기 위해 기존의 딥러닝 같은 AI는 예측 점수는 높지만 "왜 그런 결론을 내렸는지" 알 수가 없습니다. 반면 FCM은 화살표와 수치로 온갖 변수 간의 관계가 눈에 보이기 때문에, 로봇이 갑자기 멈췄을 때 "전류 화살표를 타고 들어가 보니 이 녀석이 범인이구나!" 하고 사람이 직접 눈으로 추적할 수 있어 사용했습니다.

2. 정보 흐름 기반 퍼지 인지 지도 (IF-FCM) : IF-FCM은 기존 FCM에 가짜 원인을 걸러내는 안경을 씌워준 업그레이드 버전입니다. 여기서 정보 흐름(Information Flow)은 물리학과 통계학을 기반으로 "A가 가진 정보가 실제로 B에게 전달되었는가?(진짜 인과관계가 있는가?)"를 측정하는 엄격한 필터링 기술입니다.

"우연히 같이 일어난 일(가짜 상관관계)"에 속지 않기 위해: 예를 들어, 여름철에 [아이스크림 판매량]이 늘어나면 [익사 사고]도 늘어납니다. 두 변수는 같이 움직이므로 일반 AI는 "아이스크림이 익사 사고의 원인이다!"라고 잘못 학습할 수 있습니다. (진짜 원인은 '더운 날씨'인데 말이죠.) 로봇도 마찬가지입니다. 로봇이 작동하면 당연히 [관절 온도]가 올라가고, 작동하다 보면 **[보호 정지(갑자기 멈춤)]도 일어납니다. 일반 FCM은 "온도가 높아져서 로봇이 멈췄다"고 오해하기 쉽습니다. IF-FCM은 "온도와 멈춤 사이에는 실제 정보 흐름(물리적 영향력)이 없다"는 것을 수학적으로 증명하여 이 가짜 연결고리를 끊어버립니다. 덕분에 오진율을 획기적으로 낮출 수 있어 이 기법을 도입했습니다.

3. 분산 분석 (ANOVA, Analysis of Variance) : 그룹 간의 평균 차이가 우연인지, 아니면 진짜 의미 있는 차이인지 가려내는 엄격한 수학 판사입니다. 세 개 이상의 집단이 있을 때, 그 집단들의 평균값이 서로 진짜 다른지 분산(데이터가 퍼진 정도)을 비교하여 판단하는 정통 통계 기법입니다.

AI가 내놓은 답이 진짜 맞는지 검증하는 '정답지'로 쓰기 위해: 우리가 만든 최첨단 AI(IF-FCM)가 "로봇이 멈춘 원인은 2번 관절 전류 때문입니다!"라고 주장하더라도, 이 주장을 곧이곧대로 믿기는 어렵습니다. AI도 편견이나 오류를 가질 수 있기 때문입니다. 이때 가장 신뢰할 수 있고 전통적인 통계 방법인 ANOVA를 사용하여, 실제로 로봇이 멈춘 집단과 정상 집단 사이의 '2번 관절 전류 평균값'을 비교해 봅니다. 수학 판사인 ANOVA가 "통계적으로 두 집단의 전류 값 차이는 우연이 아니며, 유의미한 원인이 맞다"라고 판결(p-value 검증)을 내려줌으로써, AI가 찾아낸 설명이 과학적으로 진짜 정답이 맞음을 교차 검증하기 위해 사용했습니다.